

Report: homework 2

Part 1: CTC Decoding

Task 1: Greedy Decode


На каждом timestep выбирается токен с наибольшей log-probability. Идущие подряд одинаковые токены дедуплицируются, blank-токены удаляются.

Dataset	WER	CER
LibriSpeech test-other	11.22%	3.81%

Task 2: Beam Search

Beam search отслеживает top-**k** prefix-ов по суммарной CTC probability (суммируя все пути, которые сворачиваются к одному тексту). Для каждого beam хранятся два score: **p_blank** и **p_non_blank**.

beam_width	WER	CER
1	11.24%	3.80%
3	11.15%	3.78%
10	11.07%	3.77%
50	11.10%	3.77%




Разброс по всем `beam_width` очень маленький (0.17% absolute WER), фактически это плато что и видно на графике. Небольшой прирост от 1 до 10 есть, но на 50 WER даже чуть отрастает обратно. Видимо, acoustic model достаточно уверена in-domain, и beam search мало что добавляет к greedy.

Task 3: Temperature Scaling

Temperature T масштабирует `logit`-ы перед `log-softmax`: logits / T . Меньше T — распределение острее, больше T — более плоское.

T	WER	CER
0.5	11.22%	3.81%
0.8	11.22%	3.81%
1.0	11.22%	3.81%
1.2	11.22%	3.81%
1.5	11.22%	3.81%
2.0	11.22%	3.81%



WER абсолютно не меняется при любой temperature. Это ожидаемо: greedy decoding берёт **argmax**


Part 2: Language Model Integration

Task 4: Shallow LM Fusion (3-gram)

На каждом шаге расширения beam итоговый score считается как:

$$\text{score} = \log_p_acoustic + \alpha * \log_p_lm + \beta * \text{num_words}$$

LM запрашивается на границах слов (когда выбрасывается word delimiter |). Сделан sweep по **alpha** $\in \{0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0\}$ и **beta** $\in \{0.0, 0.5, 1.0, 1.5\}$:



Лучшая конфигурация: alpha=0.05, beta=0.5, WER=11.00%, CER=3.75%

Основные наблюдения:

- Acoustic model уже хорошо работает in-domain, поэтому оптимальный alpha очень маленький (0.05). При $\alpha \geq 2$ качество резко падает, при $\alpha=5$ LM полностью доминирует и WER стремится к 100%.
- Небольшой word insertion bonus ($\beta=0.5$) чуть помогает - поощряет более полные гипотезы.

Task 5: 4-gram LM

Используем лучшие alpha/beta из Task 4 ($\alpha=0.05$, $\beta=0.5$):

LM	WER	CER
3-gram (LibriSpeech)	11.00%	3.75%
4-gram (LibriSpeech)	11.02%	3.76%


4-gram LM не даёт никакого улучшения по сравнению с 3-gram. Поскольку `wav2vec2-base-100h` уже хорошо настроен на LibriSpeech read speech, bottleneck тут acoustic model. Более сильная LM не может компенсировать достигнутый потолок.

Task 6: Second-pass LM Rescoring

Beam search ($\text{beam_width}=50$, без LM) строит N гипотез с acoustic log-probabilities. Затем каждая rescoring-ом:

```
score = log_p_acoustic + alpha * log_p_lm + beta * num_words
```

Выбирается гипотеза с наибольшим итоговым score.



Лучшая конфигурация: alpha=0.05, beta=0.5, WER=10.98%, CER=3.74%

Shallow fusion vs rescoring при beta=0:

alpha	SF WER%	RS WER%
0.01	11.12	11.10
0.05	11.12	11.10
0.1	11.12	11.10
0.5	11.44	11.32
1.0	11.73	11.61
2.0	17.72	12.59
5.0	99.98	15.23

Rescoring заметно стабильнее при больших значениях alpha. При alpha=2 shallow fusion деградирует до 17.72% WER, а rescoring держится на 12.59%. При alpha=5 shallow fusion вообще коллапсирует до ~100% WER, тогда как rescoring — только 15.23%.

Причина в том, что при shallow fusion LM score влияет на то, какие beams выживают на каждом timestep. Большой alpha может уничтожить правильные acoustic paths прямо во время поиска, и восстановиться уже невозможно. При rescoring beam search сначала работает чисто акустически, все **N** гипотез сохраняются, а LM только переранжирует их в конце. Она не может уничтожить гипотезу, только переставить.

Qualitative examples (beam_width=50, alpha=0.05, beta=0.5):



```

REF:  and the mere fact of his being there
BEAM: and the mere fact of his being their
SF:   and the mere fact of his being there    ✓ corrected
RS:   and the mere fact of his being there    ✓ corrected

REF:  he looked at her steadily
BEAM: he looked at her steadily
SF:   he looked at her steadily              ✓ corrected
RS:   he looked at her steadily              ✓ corrected

REF:  it was a most beautiful voice
BEAM: it was a most beautiful voice
SF:   it was a most beautiful boys           ✗ introduced error
RS:   it was a most beautiful voice          ✓ unchanged

REF:  the door was shut and locked
BEAM: the door was shut and locked
SF:   the door was shut in locked            ✗ introduced error
RS:   the door was shut and locked           ✓ unchanged

```

Task 7: Domain Shift: Earnings22


Method	LibriSpeech WER	LibriSpeech CER	Earnings22 WER	Earnings22 CER
Greedy	11.22%	3.81%	54.97%	25.58%
Beam search	11.10%	3.77%	55.03%	25.36%
Beam + 3-gram (shallow fusion)	11.00%	3.75%	55.99%	25.42%
Beam + 3-gram (rescoring)	10.98%	3.74%	55.51%	25.39%

Разрыв между in-domain (LibriSpeech) и out-of-domain (Earnings22) огромный: ~11% vs ~55% WER.

Две вероятные причины:

1. **Acoustic mismatch** — `wav2vec2-base-100h` обучался на чистой речи. В финансовых спонтанная речь, жаргон и разные условия записи.
2. **LM mismatch** — LibriSpeech 3-gram обучен на книгах и газетных текстах. Финансовой лексики нет. Shallow fusion с такой LM активно *вредит* (55.99% против 55.03% для plain beam): она штрафует правильные доменные слова и продвигает общие альтернативы.

Task 7b: Temperature × LM Fusion на Earnings22



T	Greedy WER	Beam + LM WER
0.5	54.97%	55.18%
1.0	54.97%	55.99%
1.5	54.97%	57.59%
2.0	54.97%	59.79%

- **Greedy плоский** (ожидаемо, argmax invariance работает независимо от домена).
- **Beam + LM монотонно деградирует с ростом temperature.** Более высокое T сглаживает acoustic distribution, давая LM относительно больше влияния. Но LibriSpeech LM не совпадает с финансовой речью, поэтому больше LM = больше ошибок. При $T=2.0$ WER достигает 59.79%.
- На LibriSpeech $T > 1$ тоже ухудшает качество, потому что acoustic model хорошо откалибрована и не нуждается в коррекции. На Earnings22 acoustic model плохо откалибрована и LM не соответствует домену, так что рост T бьёт сразу с двух сторон. Для улучшения здесь нужна domain-matched LM.


Task 8: Financial-domain KenLM

3-gram KenLM model обучена на `data/earnings22_train/corpus.txt` (~5000 строк, ~100k слов)

Task 9: Обе LM Оба датасета

Лучший метод декодирования: `beam_width=50, alpha=0.05, beta=0.5`.

LM	Dataset	Method	WER	CER
LibriSpeech 3-gram	LibriSpeech	Shallow fusion	11.00%	3.75%
LibriSpeech 3-gram	LibriSpeech	Rescoring	10.98%	3.74%
LibriSpeech 3-gram	Earnings22	Shallow fusion	55.99%	25.42%
LibriSpeech 3-gram	Earnings22	Rescoring	55.42%	25.40%
Financial 3-gram	LibriSpeech	Shallow fusion	11.07%	3.77%
Financial 3-gram	LibriSpeech	Rescoring	11.05%	3.76%
Financial 3-gram	Earnings22	Shallow fusion	53.98%	25.22%
Financial 3-gram	Earnings22	Rescoring	54.40%	25.29%



Какая LM лучше in-domain (LibriSpeech)? LibriSpeech 3-gram (10.98% против 11.05%). Ожидаемо: лексика и n-gram статистика прямо совпадают с тестовым доменом.

Какая LM лучше out-of-domain (Earnings22)? Financial 3-gram (53.98% SF, 54.40% RS против 55.99%/55.42% для LibriSpeech LM). Domain-matched LM возвращает ~2% absolute WER за счёт покрытия финансовой лексики, которую LibriSpeech LM штрафует.

Помогает ли domain-matched LM больше, чем большая general LM? Да. Сравнивая Task 5 (4-gram LibriSpeech, 11.02%) и Financial 3-gram на LibriSpeech (11.05%): большая general LM незначительно побеждает маленькую domain LM in-domain. Но на Earnings22 domain-matched LM выигрывает у большой general LM на ~2% absolute. Соответствие домену важнее размера модели для out-of-domain данных.

Интересно, что даже с financial LM, WER на Earnings22 остаётся ~54%. Acoustic mismatch — доминирующий bottleneck. Для существенного улучшения нужна domain-adapted acoustic model.